


Universidade Estadual Paulista "Júlio de Mesquita Filho"	
	Trabalho 2 - Computação Inspirada pela Natureza
CIN	Professor: Fabricio Aparecido - Discente: Vinicius S Santos

Escopo do Trabalho

O presente trabalho tem como objetivo aplicar técnicas de redes neurais artificiais, especificamente o Perceptron e perceptrons multicamadas (MLP), em diferentes bases de dados públicas disponíveis no UCI Machine Learning Repository. Cada exercício proposto visa explorar conceitos fundamentais do aprendizado supervisionado e redes neurais, incluindo separabilidade linear, estratégias de normalização, particionamento de dados, tuning de hiperparâmetros, e análise de desempenho com métricas apropriadas.

Os experimentos foram conduzidos utilizando a linguagem Python no ambiente Google Colab, com suporte das bibliotecas NumPy, scikit-learn, matplotlib e TensorFlow/Keras. O código-fonte completo encontra-se disponível em repositório público para consulta e reprodutibilidade dos resultados.

Exercício 1 – Dataset Iris com Perceptron


Neste exercício, utilizou-se o conhecido conjunto de dados *Iris*, que contém 150 amostras de três espécies da flor *Iris*: *setosa*, *versicolor* e *virginica*. Cada instância é descrita por quatro atributos numéricos: comprimento e largura da sépala e da pétala.

Pré-processamento dos Dados

Inicialmente, os dados foram normalizados utilizando a técnica *StandardScaler*, que transforma os atributos para média zero e desvio padrão igual a um. Essa etapa é essencial para melhorar a eficiência e estabilidade da convergência do Perceptron. Em seguida, os dados foram divididos em três subconjuntos: 70% para treinamento, 15% para validação e 15% para teste.

Treinamento com Perceptron Multiclasse

Foi implementado um modelo Perceptron com abordagem *One-vs-Rest* (OvR), treinando três classificadores binários, um para cada classe do problema. A função de ativação utilizada foi a degrau (step function), com treinamento baseado no erro quadrático médio (MSE) ao longo das épocas. Diversas taxas de aprendizado foram avaliadas, com destaque para $\eta = 0,01$.

Universidade Estadual Paulista "Júlio de Mesquita Filho"	
	Trabalho 2 - Computação Inspirada pela Natureza
CIN	Professor: Fabricio Aparecido - Discente: Vinicius S Santos




Figura 1: Convergência do Erro Quadrático Médio por Época para cada classe (Iris Dataset)


Análise dos Resultados

O gráfico de convergência indica que as classes *Setosa* e *Virginica* foram rapidamente aprendidas pelo modelo, com MSE tendendo a zero ainda nas primeiras épocas. Em contrapartida, a classe *Versicolor* apresentou instabilidade no erro, sinalizando dificuldade na separação linear desta classe em relação às demais.

Matrizes de Confusão e Acurácia

As métricas de avaliação incluíram acurácia e matriz de confusão para os três subconjuntos. Os resultados obtidos foram:

- **Treinamento:** Acurácia de 82,86%. A classe *Setosa* foi perfeitamente classificada, enquanto *Versicolor* e *Virginica* apresentaram confusões mútuas.
- **Validação:** Acurácia de 59,09%. Observou-se queda significativa, indicando possível sobreajuste ao conjunto de treino.
- **Teste:** Acurácia de 82,61%. Desempenho semelhante ao do treinamento, sugerindo boa generalização.

Universidade Estadual Paulista "Júlio de Mesquita Filho"	
	Trabalho 2 - Computação Inspirada pela Natureza
CIN	Professor: Fabricio Aparecido - Discente: Vinicius S Santos




Figura 2: Matrizes de Confusão para os conjuntos de Treinamento, Validação e Teste

Conclusão

O modelo Perceptron foi eficiente para classes linearmente separáveis, como a *Setosa*, mas apresentou limitações nas fronteiras de decisão envolvendo *Versicolor* e *Virginica*, que possuem sobreposição de atributos. Esses resultados são coerentes com a teoria do Perceptron, que é adequado apenas para problemas linearmente separáveis. A adoção de modelos mais complexos, como redes multicamadas, é recomendada para superar tais restrições.

Exercício 2 – Dataset Wine com Perceptron


O segundo experimento utilizou o dataset *Wine*, também oriundo do repositório UCI, composto por 178 amostras de vinho de três diferentes cultivares italianas, cada uma descrita por 13 atributos físico-químicos, como teor alcoólico, concentração de minerais e fenóis, entre outros.

Pré-processamento dos Dados

Assim como no primeiro experimento, aplicou-se a normalização dos atributos com *StandardScaler*. Em seguida, os dados foram divididos nos mesmos percentuais de treino (70%), validação (15%) e teste (15%), respeitando a distribuição estratificada das classes.

Treinamento com Perceptron One-vs-Rest

Adotou-se novamente a estratégia *One-vs-Rest*, com três perceptrons binários treinados separadamente. Cada perceptron foi treinado para reconhecer uma das classes como positiva e as demais como negativas. A função de perda utilizada foi o Erro Quadrático Médio (MSE), monitorado ao longo das épocas de treinamento.

Universidade Estadual Paulista "Júlio de Mesquita Filho"	
	Trabalho 2 - Computação Inspirada pela Natureza
CIN	Professor: Fabricio Aparecido - Discente: Vinicius S Santos




Figura 3: Curvas de convergência do erro (MSE) por época para cada classe (Wine Dataset)


Análise dos Resultados

Observou-se que as curvas de MSE para as classes 0 e 2 apresentaram convergência rápida, sugerindo que essas classes são linearmente separáveis das demais. Por outro lado, a classe 1 demonstrou maior persistência de erro nas primeiras épocas, indicando sobreposição de características com as outras classes e dificuldade do modelo em ajustar a fronteira de decisão.

Matrizes de Confusão e Acurácia

A seguir são apresentados os resultados obtidos para cada subconjunto:

- **Treinamento:** Acurácia de 100%, com classificação perfeita das amostras.
- **Validação:** Acurácia de 96,30%, com apenas uma amostra da classe 1 classificada incorretamente como classe 0.
- **Teste:** Acurácia de 88,89%, com erros localizados principalmente na classe 2.

Universidade Estadual Paulista "Júlio de Mesquita Filho"	
	Trabalho 2 - Computação Inspirada pela Natureza
CIN	Professor: Fabricio Aparecido - Discente: Vinicius S Santos




Figura 4: Matrizes de Confusão para Treinamento, Validação e Teste (Wine Dataset)

Conclusão

O modelo Perceptron foi altamente eficaz no conjunto de treinamento, atingindo acurácia perfeita. A ligeira queda nos conjuntos de validação e teste indica um comportamento de generalização adequado, com destaque para o bom desempenho mesmo em um problema com maior número de atributos. A dificuldade em classificar a classe 1 sugere que nem todas as separações são linearmente bem definidas, apontando a necessidade de modelos com maior capacidade de representação para cenários mais complexos.

Exercício 3 – Redes Neurais no Dataset Breast Cancer


O terceiro experimento teve como foco a aplicação de redes neurais multicamadas (MLP) sobre o conjunto de dados *Breast Cancer Wisconsin*, disponível no repositório UCI. Trata-se de um problema de classificação binária entre tumores benignos e malignos, com 569 instâncias descritas por 30 atributos derivados de imagens de exames histopatológicos.

Pré-processamento dos Dados

Os dados foram normalizados com *StandardScaler*, e posteriormente divididos em três subconjuntos: 70% para treinamento, 15% para validação e 15% para teste. A divisão foi estratificada, mantendo a proporção das classes em todos os conjuntos.

Arquitetura 1 – MLP com 1 Camada Oculta

A primeira rede neural testada possui uma única camada oculta com 16 neurônios e função de ativação ReLU. A camada de saída utiliza função Sigmoid, adequada à classificação binária. A rede foi treinada por 100 épocas com otimizador Adam e função de perda *binary crossentropy*.

Universidade Estadual Paulista "Júlio de Mesquita Filho"	
	Trabalho 2 - Computação Inspirada pela Natureza
CIN	Professor: Fabricio Aparecido - Discente: Vinicius S Santos

- Acurácia no teste: **96,51%**
- Baixo erro de generalização entre treino, validação e teste
- Classificou corretamente 83 das 86 amostras de teste





Figura 5: Curvas de Perda e Acurácia, e Matriz de Confusão – MLP com 1 camada oculta

Arquitetura 2 – MLP com 2 Camadas Ocultas

Na segunda arquitetura, foi adicionada uma camada oculta extra com 32 neurônios, seguida por uma camada de 16 neurônios, ambas com ativação ReLU. A estrutura buscou aumentar a capacidade de representação do modelo.

- Acurácia no teste: **96,51%**
- Desempenho similar ao da rede anterior
- Estabilidade nas curvas de validação; ausência de overfitting

Universidade Estadual Paulista "Júlio de Mesquita Filho"	
	Trabalho 2 - Computação Inspirada pela Natureza
CIN	Professor: Fabricio Aparecido - Discente: Vinicius S Santos

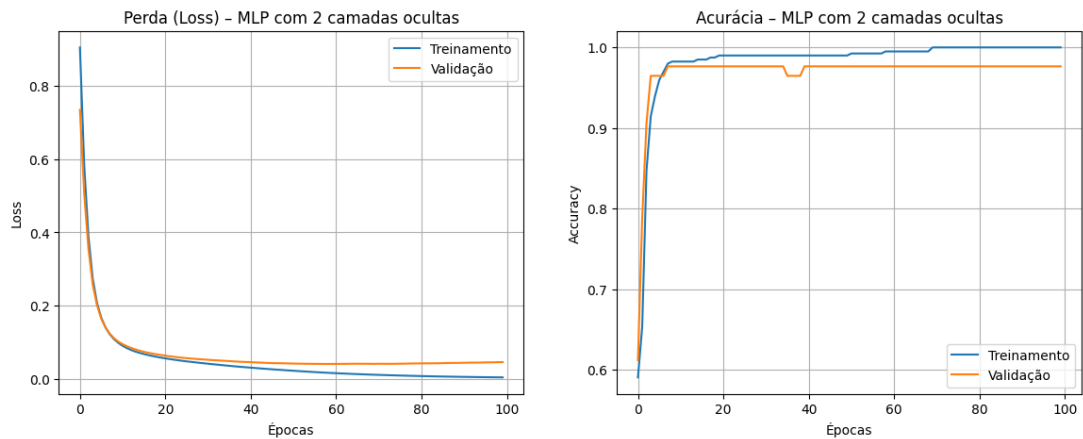


Figura 6: Curvas de Perda e Acurácia, e Matriz de Confusão – MLP com 2 camadas ocultas

Arquitetura 3 – MLP com Regularização (Dropout)

Na terceira arquitetura, foram inseridas camadas de *Dropout* com taxa de 30% entre as camadas ocultas, como técnica de regularização para reduzir overfitting.

- Acurácia no teste: **97,67%**
- Melhor desempenho entre as arquiteturas testadas
- Apenas dois erros na matriz de confusão

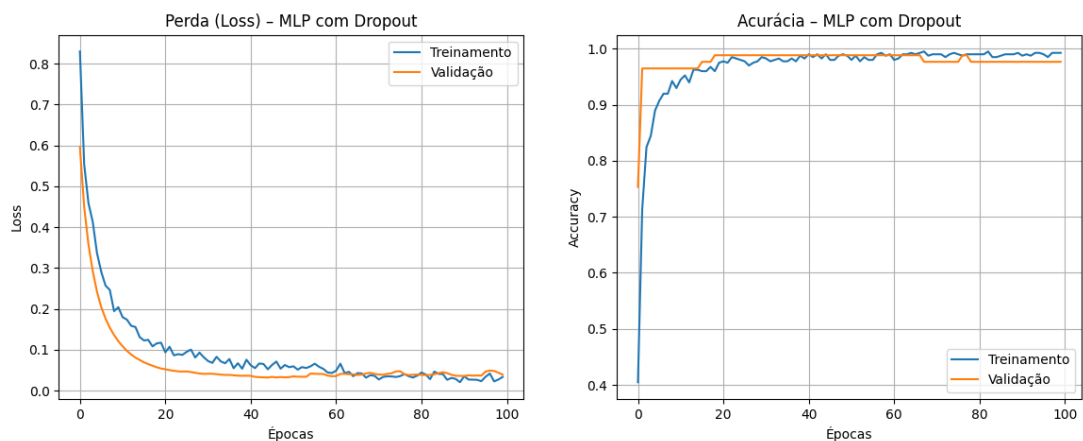



Figura 7: Curvas de Perda e Acurácia, e Matriz de Confusão – MLP com Dropout

Universidade Estadual Paulista "Júlio de Mesquita Filho"	
	Trabalho 2 - Computação Inspirada pela Natureza
CIN	Professor: Fabricio Aparecido - Discente: Vinicius S Santos

Comparação entre Arquiteturas

Tabela 1: Resumo comparativo das arquiteturas testadas

Arquitetura	Acurácia	Observações
MLP – 1 camada oculta	96,51%	Estrutura simples e eficiente, rápida convergência
MLP – 2 camadas ocultas	96,51%	Maior capacidade de modelagem, porém sem ganhos expressivos
MLP – com Dropout	97,67%	Melhor generalização; regularização eficaz contra overfitting

Conclusão

O experimento evidenciou que mesmo arquiteturas simples, como uma MLP com uma única camada oculta, são capazes de atingir elevado desempenho neste conjunto de dados. No entanto, a inclusão de *Dropout* demonstrou potencial de melhoria na acurácia e robustez do modelo.

Conclusão Geral


O presente trabalho propôs a aplicação prática de técnicas de redes neurais artificiais em três cenários distintos de classificação, utilizando conjuntos de dados clássicos da literatura: *Iris*, *Wine* e *Breast Cancer Wisconsin*. As abordagens foram implementadas em ambiente computacional baseado em Python e executadas no Google Colab, com uso de bibliotecas especializadas em aprendizado de máquina e redes neurais.

No **primeiro experimento**, observou-se que o modelo Perceptron foi eficiente para a classe linearmente separável do conjunto *Iris*, mas apresentou limitações ao lidar com sobreposição de classes, confirmando sua inadequação para problemas não linearmente separáveis.

O **segundo exercício** confirmou a eficiência do Perceptron no conjunto *Wine*, com alto desempenho em treinamento e generalização satisfatória, embora dificuldades pontuais tenham sido observadas em uma das classes, sugerindo a presença de fronteiras de decisão complexas.

No **terceiro experimento**, redes neurais multicamadas (MLPs) foram utilizadas no problema de classificação binária de câncer de mama. Três arquiteturas distintas foram comparadas. A arquitetura com regularização por *Dropout* obteve o melhor desempenho (acurácia de 97,67%), evidenciando o papel fundamental da regularização para evitar overfitting e melhorar a generalização.

Os resultados obtidos ao longo dos três exercícios ilustram o potencial das redes neurais artificiais na resolução de tarefas de classificação supervisionada, bem como a importância de práticas como normalização, particionamento adequado dos dados, escolha de arquiteturas e

Universidade Estadual Paulista "Júlio de Mesquita Filho"	
	Trabalho 2 - Computação Inspirada pela Natureza
CIN	Professor: Fabricio Aparecido - Discente: Vinicius S Santos

técnicas de regularização. Tais práticas são essenciais para a construção de modelos preditivos robustos e confiáveis.

Este estudo reforça a relevância do aprendizado supervisionado como ferramenta poderosa na Ciência de Dados, além de destacar o valor pedagógico da experimentação prática no processo de assimilação dos conceitos de Computação Inspirada pela Natureza.